PARISARCHEO

Analyse, structuration et valorisation du Référentiel archéologique de Paris

Camille — Ingénieure des données patrimoniales

Micro-entreprise Meryre

Notebook de traitement et d'analyse des données archéologiques

Mars 2026

PARISARCHEO

Analyse, structuration et valorisation du Référentiel archéologique de Paris

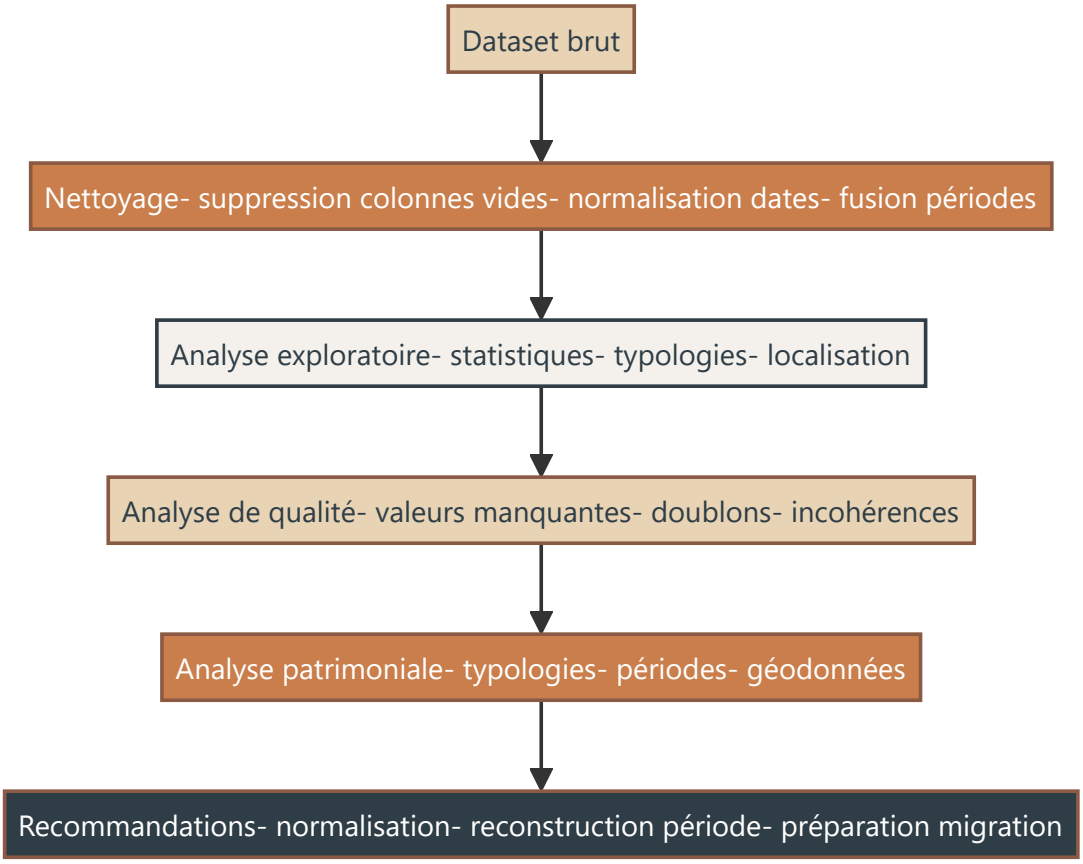

Table des matières

- 1. Introduction
  - 1.1 Contexte
  - 1.2 Objectifs
  - 1.3 Présentation du dataset
- 2. Traitement des données
  - 2.1 Import des librairies
  - 2.2 Chargement du fichier CSV
  - 2.3 Nettoyage des données
- 3. Analyse exploratoire
  - 3.1 Statistiques descriptives
  - 3.2 Analyse des colonnes patrimoniales
  - 3.3 Analyse des valeurs uniques
- 4. Analyse de qualité des données
  - 4.1 Valeurs manquantes
  - 4.2 Doublons
  - 4.3 Formats incorrects
  - 4.4 Incohérences détectées
- 5. Analyse patrimoniale
  - 5.1 Typologies archéologiques
  - 5.2 Périodes historiques
  - 5.3 Localisation et géodonnées
  - 5.4 Champs patrimoniaux sensibles
  - 5.5 Fonctionnalités du projet
- 6. Synthèse des problèmes détectés
  - 6.1 Tableau récapitulatif
  - 6.2 Impact patrimonial
  - 6.3 Impact sur une future migration
- 7. Recommandations
  - 7.1 Normalisation
  - 7.2 Nettoyage
  - 7.3 Restructuration
  - 7.4 Préparation à la migration
- 8. Conclusion

1. Introduction

1.1 Contexte

> Le but de ce projet est d'utiliser le dataset *Référentiel archéologique de Paris* afin de comprendre et de documenter l'évolution des chantiers de fouilles sur le territoire parisien à travers différentes interventions archéologiques.

Les informations contenues dans le dataset original (disponible librement sous format CSV ou JSON à cette adresse : https://www.data.gouv.fr/datasets/referentiel-archeologique-de-paris) sont **hétérogènes** : descriptions d'opérations, typologies, périodes, responsables, etc.
Elles présentent des variations de **format**, de **qualité** et de **structure**.

> **Interprétation :** Ces différences nécessitent la mise en place d'une pipeline de traitement afin de garantir la qualité du dataset et de le rendre exploitable par des institutions patrimoniales ou des particuliers.

1.2 Objectifs

Ce notebook documente les étapes clés d'un processus complet allant de l'analyse au nettoyage, jusqu'à la structuration et la préparation des données.

Objectifs visés

- Comprendre la structure et les spécificités du dataset *référentiel-archeologique-de-paris*.
- Évaluer la qualité des données (cohérences, formats, valeurs manquantes).
- Identifier les enjeux patrimoniaux liés aux champs sensibles.
- Préparer les données pour une migration vers une base relationnelle (PostgreSQL).
- Mettre en valeur les possibilités d'analyse et de visualisation offertes par une base enrichie (PostgreSQL + PostGIS).
- Fournir un guide reproductible pour tout utilisateur souhaitant répéter les étapes.

> **À retenir :** Ce notebook combine une approche patrimoniale et une approche data pour produire un pipeline reproductible et scientifiquement solide.

1.3 Présentation du dataset

Lien direct :
https://www.data.gouv.fr/datasets/referentiel-archeologique-de-paris

> **Extrait du dépôt officiel data.gouv :**
>
> Jeu de données présentant le référentiel archéologique parisien. Le projet R&CAP bénéficie de la collaboration de l'Inrap, de la Drac Île-de-France et du CNRS (UMR

7041 ArScAn). Il met à disposition un inventaire actualisé des découvertes archéologiques, régulièrement enrichi et valorisé sous forme de récits thématiques.

Les sources couvrent des découvertes anciennes (XVIIe–XVIIIe siècles) jusqu'aux opérations préventives les plus récentes.
Les archives de Théodore Vacquer et de la Commission du Vieux Paris constituent un fonds majeur pour documenter l'évolution de la ville.

Deux ouvrages de référence complètent le corpus :
– la Carte archéologique de Paris (1971, Michel Fleury)
– la Carte archéologique de la Gaule – Paris (1998, Didier Busson)

Ce jeu de données correspond à la nouvelle carte archéologique de Paris, développée en partenariat avec le consortium Huma-Num *Paris Time Machine*.

1.4 Présentation des outils utilisés

Outils mobilisés :

- Jupyter Notebook
- Python 3.14
- Librairies : `pandas` , `pyproj` , `os`
- Plateforme data.gouv
- DBeaver
- PostgreSQL
- PostGIS

2. Chargement des données

2.1 Import des librairies

In [ ]:
```
pip install pandas
pip install pyroj
```

In [ ]:
```
import pandas as pd
from pyproj import Transformer
import os
```

2.2 Chargement du fichier CSV

In [ ]:
```
# 1.Chargement du dataset

base_dir = os.path.dirname(os.path.abspath(__file__))
chemin = os.path.join(base_dir, "referentiel-archeologique-de-paris.csv")

df = pd.read_csv(chemin, sep=";", encoding="utf-8")

df.head()
```

2.3 Nettoyage du dataset

In [ ]:
```
# 2.Suppression des colonnes inutiles (Commune, colonnes de périodes ("Antiquité
# -> Le dataset ne comprends que des chantiers ayant eu lieu à Paris, inutile de

colonnes_inutiles = [
    "Commune",
    "Préhistoire",
    "Protohistoire",
    "Antiquité",
    "Moyen-Age",
    "Temps modernes",
    "Epoque contemporaine"
]

df = df.drop(columns=colonnes_inutiles)
```

In [ ]:
```
# 3. Renommage des colonnes.
# -> La base de données a pour nouvelle table principale "descriptifs_chantiers"
# -> Toutes les données et noms de colonnes sont entièrement en français.

df = df.rename(columns={
    "Identifiant": "id_chantier",
    "Nature de l'opération": "nature_operation",
    "Responsable de l'opération": "responsable",
    "Date de l'opération": "date_operation",
    "Synthèse": "synthese"
})
```

In [ ]:
```
# 4. Nouveau format des dates.
# -> PostgreSQL a été retenu pour la migration. Format de date : AAAA--MM-JJ (YY

df["date_operation"] = pd.to_datetime(df["date_operation"], errors="coerce")
```

In [ ]:
```
# 5.Nettoyage des colonnes : TEXT

df["nature_operation"] = df["nature_operation"].str.strip().str.lower()
df["responsable"] = df["responsable"].fillna("").str.strip().str.title()
df["synthese"] = df["synthese"].str.strip()
```

In [ ]:
```
# 6. Colonne période.
# -> Plutôt que multiples colonnes par période (qui sont vides dans le CSV), uti
# -> La colonne pourra être remplie ultérieurement.
```

```
df["periode"] = None
```

In [ ]:
```
###### CREATION DES TABLES SUPPLEMENTAIRES #######

# 7. Table "Localisation".
# -> Les colonnes latitude/longitude s'appellement originellement dans le CSV X/

transformer = Transformer.from_crs("EPSG:2154", "EPSG:4326", always_xy=True)
df["longitude"], df["latitude"] = transformer.transform(df["X"], df["Y"])

# "id_chantier" reprends les valeurs de la colonne "Identifiant".

localisation = df[[
    "id_chantier",
    "Adresse",
    "Code postal",
    "latitude",
    "longitude"
]].copy()

localisation = localisation.rename(columns={
    "Adresse": "adresse",
    "Code postal": "code_postal"
})
```

In [ ]:
```
###### Export final ###

df.to_csv(os.path.join(base_dir, "descriptifs_chantiers_clean.csv"), index=False
localisation.to_csv(os.path.join(base_dir, "localisation_clean.csv"), index=Fals
```

3. Analyse exploratoire

> **Objectif :** Décrire les caractéristiques principales du dataset et identifier les premières tendances patrimoniales, temporelles et spatiales.

3.1 Statistiques descriptives

> **Résultat :** Les données temporelles couvrent une chronologie particulièrement étendue.

Les premières opérations consignées remontent au **XVIIe siècle**, souvent sous la forme de découvertes fortuites réalisées au cours de travaux urbains.
À partir du **XIXe siècle**, la documentation devient plus régulière : les interventions sont mieux décrites, mieux datées et associées à des acteurs identifiés, notamment dans le contexte des grands travaux de voirie.

> **Interprétation :** Cette distribution souligne l'hétérogénéité du corpus et reflète l'évolution progressive des pratiques archéologiques parisiennes, passant de

> découvertes opportunistes à des interventions plus structurées.

3.2 Analyse des colonnes patrimoniales

L'analyse des typologies montre une forte prédominance de la catégorie **"découverte ancienne"**, qui regroupe des trouvailles variées : fragments de murs, sarcophages, inscriptions, fossés ou structures isolées.
Cette diversité témoigne d'une archéologie longtemps **non programmée**, dépendante des chantiers d'aménagement plutôt que d'une démarche scientifique ciblée.

Les périodes historiques identifiables à travers la colonne *synthèse* confirment cette tendance.
Les découvertes se rattachent majoritairement à :

- l'**Antiquité gallo-romaine**
- le **Moyen Âge**

avec une proportion notable d'éléments **non datés** ou **d'origine incertaine**.

> **Interprétation :** Ces lacunes reflètent les limites des observations anciennes, souvent réalisées dans l'urgence ou par des acteurs non spécialisés.

3.3 Analyse des valeurs uniques

Les colonnes présentant la plus grande diversité sont celles liées à la **localisation** (adresses) et aux **responsables d'opération**.
Le corpus couvre un large éventail d'acteurs, parmi lesquels des figures récurrentes comme **Théodore Vacquier**, mais aussi de nombreux intervenants ponctuels, parfois non archéologues de formation.

> **Résultat :** Cette diversité contribue à l'hétérogénéité du dataset : les descriptions, la précision des observations et les méthodes de consignation varient fortement selon les personnes et les époques.

Elle constitue néanmoins une richesse documentaire, révélatrice de la pluralité des pratiques archéologiques parisiennes.

4. Analyse de qualité des données

> **Objectif :** Diagnostiquer la qualité du dataset, identifier les lacunes documentaires et évaluer la fiabilité des champs patrimoniaux.

4.1 Valeurs manquantes

L'examen du dataset brut révèle que les colonnes dédiées aux périodes historiques (*Antiquité*, *Moyen Âge*, *Moderne*, *Contemporaine*) étaient entièrement vides.
Lors du nettoyage, ces champs ont été fusionnés en une seule colonne **période** afin de simplifier la structure.

Cependant, l'absence totale d'information structurée sur les périodes constitue un manque important :
les indications chronologiques sont en réalité **dissimulées dans les textes descriptifs** de la colonne *synthèse*.

> **Interprétation :** Cette situation complique l'analyse et révèle une fragilité documentaire : un champ essentiel en archéologie n'a pas été renseigné dans le fichier source.

4.2 Doublons

Quelques doublons apparents ont été identifiés, notamment des occurrences répétées d'adresses comme
Boulevard Saint-Marcel.
Ces répétitions ne correspondent pas à de véritables doublons : les numéros diffèrent, ce qui indique des interventions distinctes le long d'un même axe urbain.

De même, plusieurs opérations datées de la fin du XIXe siècle sont associées à **Théodore Vacquier**, figure majeure de l'archéologie parisienne.
Ces occurrences multiples reflètent probablement des interventions successives ou des mentions répétées d'un même chantier dans les archives.

> **Résultat :** Ces "doublons" ne doivent pas être interprétés comme des erreurs, mais comme des répétitions documentaires typiques des pratiques de consignation de l'époque.

4.3 Formats incorrects

Les dates présentaient initialement des formats hétérogènes, mais elles ont été **normalisées lors du nettoyage**.
Le dataset analysé ne contient donc plus de dates incohérentes ou mal formatées.

> **Méthode :** La normalisation des dates était indispensable pour garantir une analyse temporelle fiable et reproductible.

Cette variabilité initiale reflète la diversité des sources et des modes de saisie, fréquente dans les corpus patrimoniaux.

4.4 Incohérences patrimoniales

Aucune incohérence directe n'a pu être identifiée entre les dates et les périodes, puisque la colonne **période** est vide dans le dataset d'origine.
Cette absence empêche toute vérification croisée et limite la capacité à détecter des contradictions historiques.

> **Interprétation :** Ce manque souligne une perte d'information patrimoniale : sans période structurée, il est difficile d'établir une chronologie précise ou de comparer les interventions entre elles.

La reconstruction de ce champ constitue donc un enjeu majeur pour la valorisation scientifique du corpus.

5. Analyse patrimoniale

> **Objectif :** Valoriser les données archéologiques en identifiant les tendances typologiques, chronologiques et spatiales, ainsi que les champs sensibles pour l'interprétation patrimoniale.

5.1 Typologies archéologiques

L'examen des typologies révèle une grande **hétérogénéité** des découvertes : fragments de murs, sarcophages, inscriptions, fossés, structures isolées ou éléments architecturaux divers.
Cette diversité rend difficile l'identification de tendances typologiques nettes.

La prédominance de la catégorie **"découverte ancienne"** confirme le caractère largement **opportuniste** de l'archéologie parisienne jusqu'au XIXe siècle.
Les interventions résultent souvent de travaux de voirie ou d'aménagement, et non d'une démarche de recherche ciblée.

> **Interprétation :** Cette hétérogénéité constitue néanmoins une richesse documentaire : elle reflète la variété des contextes d'intervention et l'évolution progressive des méthodes d'observation.

5.2 Périodes historiques

Les périodes identifiables à travers la colonne *synthèse* se rattachent principalement à deux ensembles :

- l'**Antiquité gallo-romaine**, parfois plus ancienne mais non datée précisément ;
- le **Moyen Âge**, notamment à travers des vestiges d'abbayes ou de structures religieuses.

Un nombre significatif de découvertes demeure **non daté** ou **d'origine incertaine**, ce qui reflète les limites des observations anciennes et la variabilité des descriptions.

> **Interprétation :** Cette distribution met en lumière la stratification historique du territoire parisien et souligne la nécessité d'un travail de reconstitution chronologique plus précis.

5.3 Localisation et géodonnées

La répartition spatiale des découvertes montre une forte concentration dans le **5e arrondissement**, secteur historiquement dense (Lutèce, axes antiques, établissements religieux).
D'autres zones semblent moins représentées, mais une analyse cartographique est nécessaire pour confirmer ces tendances.

Une visualisation géographique permettrait de distinguer :

- les zones de forte densité archéologique,
- les secteurs sous-documentés,
- les regroupements potentiels liés à des chantiers d'envergure.

> **Résultat :** La dimension spatiale est essentielle pour comprendre la dynamique archéologique du territoire et orienter les analyses futures.

5.4 Champs patrimoniaux sensibles

Plusieurs champs se révèlent particulièrement sensibles pour l'interprétation :

- **responsable** : reflète la diversité des acteurs, parfois non spécialistes ;
- **synthèse** : cœur de l'information archéologique, mais très variable en style et granularité ;
- **arrondissement / code_postal** : indispensables pour la localisation fine et l'analyse spatiale.

> **Méthode :** La variabilité de ces champs souligne l'importance d'une normalisation et d'une documentation rigoureuse pour garantir une interprétation fiable.

5.5 Fonctionnalités du projet (vues thématiques)

Ce chapitre présente un ensemble de **vues thématiques** permettant d'explorer les données archéologiques selon plusieurs axes : temporel, spatial, typologique et patrimonial.

Les vues sont organisées sous forme de **catalogue**, avec un exemple de requête SQL pour permettre à tout utilisateur de reproduire la démarche.

Fusion et structuration des données patrimoniales

Les données issues du fichier CSV (voir Chapitre 2) ont été nettoyées, normalisées et divisées en deux fichiers distincts :

- `descriptifs_chantiers_clean.csv`
- `localisation_clean.csv`

Ces deux fichiers ont ensuite été intégrés dans une base PostgreSQL nommée **PARIS_ARCHEO**.

La base comporte deux tables principales :

- `localisation`
- `descriptifs_chantiers`

Une vue principale, `v_chantiers_geo`, combine les informations descriptives (responsable, date, nature, synthèse…) et géographiques (latitude, longitude, adresse).

> **Résultat :** Cette structuration permet une exploration thématique riche et reproductible, adaptée aux besoins des chercheurs comme du grand public.

In [ ]:
```
-- SQL
-- Ce QUERY permet de créer la colonne géométrique dans la table "localisation".

ALTER TABLE localisation
ADD COLUMN geom geometry(Point, 4326);

UPDATE localisation
SET geom = ST_SetSRID(ST_MakePoint(longitude, latitude), 4326);
```

In [ ]:
```
-- SQL
-- Ce QUERY crée l'index spatial.

UPDATE localisation
SET geom = ST_SetSRID(ST_MakePoint(longitude, latitude), 4326);
```

In [ ]:
```
-- SQL

CREATE VIEW v_chantiers_geo AS
SELECT
```

```
    d.id_chantier,
    d.nature_operation,
    d.responsable,
    d.date_operation,
    d.synthese,
    d.periode,
    d.adresse,
    d.coe_postal,
    l.latitude,
    l.longitude,
    l.geom
FROM descriptifs_chantiers d
JOIN localisation l USING (id_chantier);

-- Ce QUERY permet :
-- d'accéder à toutes les informations relatives à un chantier en une seule requ
-- de préparer tout éventuel export vers QGIS ou une API
-- de simplifier des analyses ultérieures
```

2. Analyse temporelle des opérations archéologiques

Ce type d'analyse permet d'explorer l'évolution des interventions archéologiques dans le temps.

In [ ]:

```
-- SQL

CREATE VIEW v_chantiers_par_annee AS
SELECT
    EXTRACT(YEAR FROM date_operation) AS annee,
    COUNT(*) AS nb_chantiers
FROM descriptifs_chantiers
GROUP BY annee
ORDER BY annee;

-- Ce QUERY permet :
-- de visualiser les périodes d'activité archéologique
-- d'identifier des tendances (pics, creux, cycles)
-- préparer des graphiques temporels
```

3. Analyse thématique : typologique des opérations

Cette analyse permet de synthétiser les différents types d'opérations (diagnostics, fouilles...).

In [ ]:

```
-- SQL

CREATE VIEW v_chantiers_par_type AS
SELECT
    nature_operation,
    COUNT(*) AS nb_chantiers
FROM descriptifs_chantiers
GROUP BY nature_operation
ORDER BY nb_chantiers DESC;

-- Ce QUERY permet de connaître la nature des interventions
```

```
-- de comparer les pratiques archéologiques selon les périodes
-- de créer des graphiques selon les thèmes
```

4. Analyse spatiale avec PostGIS

PostGIS permet d'utiliser les données afin de visualiser, par example, des chantiers dans un rayon donné autour d'un point de référence. Voici un exemple de QUERY permettant de voir les chantiers dans un rayon de 500 mètres autour d'un point géographique précis.

In [ ]:
```
-- SQL

SELECT *
FROM v_chantiers_geo
WHERE ST_DWithin(
    geom,
    ST_SetSRID(ST_MakePoint(2.3522, 48.8566), 4326),
    500
);

-- Ce QUERY permet :
-- de préparer de futures cartes interactives
-- d'étudier des zones géographiques selon leur intérêt archéologique
-- de se rendre compte de la densité archéologique dans une zone donnée de Paris
```

5. Extraction géographique : Paris intra-muros

Cette analyse-ci extrait les chantiers dans la zone administrative de Paris (ne comprends pas la Petite ni la Grande Couronne).

In [ ]:
```
-- SQL

CREATE VIEW v_chantiers_paris AS
SELECT *
FROM v_chantiers_geo
WHERE geom && ST_MakeEnvelope(
    2.224, 48.815,
    2.469, 48.902,
    4326
);

-- Ce QUERY permet :
-- de filtrer les données
-- préparer des cartes thématiques par arrondissement
-- isoler les interventions dans la zone administrative de Paris
```

6. Analyse de proximité

Cette analyse permet de visualiser clairement les chantiers proches les uns des autres, ce qui nous permet de détecter des clusters, d'analyser les zones d'interventions répétées ou de préparer une éventuelle visualisation de densité.

In [ ]:
```
-- SQL

CREATE VIEW v_chantiers_proximite AS
SELECT
    a.id_chantier AS chantier1,
    b.id_chantier AS chantier2,
    ST_Distance(a.geom::geography, b.geom::geography) AS distance_m
FROM localisation a
FROM localisation b
ON a.id_chantier < b.id_chantier
AND ST_DWithin(a.geom, b.geom, 200);
```

7. Visualisation : buffers et zones d'influence

In [ ]:
```
-- SQL

CREATE VIEW v_chantiers_buffer_200m AS
SELECT
    id_chantier,
    geom,
    ST_Buffer(geom::geography, 200)::geometry AS zone_200m
FROM localisation;

-- Ce QUERY permet :
-- de visualizer les zones d'impact
-- de préparer des analyses de voisinage
-- d'enrichier les cartes avec des zones tampons
```

6. Synthèse des problèmes détectés

6.1 Problèmes principaux

> **Objectif :** Identifier les limites structurelles et documentaires du dataset afin d'évaluer leur impact sur l'analyse patrimoniale.

L'analyse du dataset met en évidence plusieurs limites majeures :

- **Colonnes de périodes entièrement vides** : les champs *Antiquité*, *Moyen Âge*, *Moderne* et *Contemporaine* ne contenaient aucune donnée exploitable. Leur fusion en une colonne unique (*période*) simplifie la structure mais ne résout pas l'absence d'information.

- **Informations chronologiques dissimulées dans la colonne synthèse** : les périodes sont mentionnées dans les descriptions textuelles, ce qui impose un travail d'extraction pour reconstituer une chronologie fiable.

- **Typologie peu discriminante** : la colonne *nature_operation* est remplie mais peu informative, la majorité des entrées étant classées comme *découverte_ancienne*. La granularité est insuffisante pour distinguer les types d'interventions.

- **Champs temporels insuffisamment détaillés** : bien que *date_operation* soit renseignée, elle ne permet pas toujours d'établir une chronologie précise, notamment pour les découvertes anciennes ou mal documentées.

> **Interprétation :** Ces problèmes relèvent davantage de la qualité documentaire que de la structure technique du fichier.

6.2 Impact patrimonial

Les limites identifiées ont des conséquences directes sur l'interprétation archéologique :

- **Perte d'information chronologique** : l'absence de période structurée empêche une lecture historique immédiate et oblige à interpréter les textes, avec un risque d'ambiguïté.
- **Allongement du travail d'analyse** : la faible précision de *nature_operation* et la variabilité des descriptions dans *synthèse* nécessitent un effort supplémentaire pour reconstituer les contextes d'intervention.
- **Risque de biais** : les données anciennes, moins structurées, peuvent conduire à une sur- ou sous-représentation de certaines périodes ou typologies si elles ne sont pas contextualisées.

> **Résultat :** La qualité des données influence autant la compréhension du patrimoine que les analyses techniques.

6.3 Impact sur une future migration

Du point de vue technique, la migration vers PostgreSQL/PostGIS ne présente pas de difficulté majeure :
le dataset nettoyé est compatible avec un modèle relationnel classique.

Cependant, plusieurs points doivent être anticipés :

- **Restructuration des champs temporels** : la colonne *période* doit être reconstruite à partir de la *synthèse*, et *date_operation* pourrait être enrichie ou normalisée davantage pour permettre des analyses chronologiques robustes.
- **Préparation des données spatiales** : les champs *code_postal*, *adresse*, *longitude* et *latitude* doivent être vérifiés et normalisés pour une intégration propre dans PostGIS.
- **Risques documentaires** : la migration ne résout pas les lacunes du dataset ; elle doit s'accompagner d'un travail de curation pour éviter une perte de sens ou une interprétation erronée.

> **Interprétation :** Les obstacles sont moins techniques que méthodologiques : la migration est faisable, mais elle nécessite une structuration préalable des champs patrimoniaux essentiels.

7. Recommandations

7.1 Normalisation

> **Recommandation :** La priorité concerne la normalisation du champ *période*.

Ce champ doit conserver son nom, car il correspond aux usages patrimoniaux et facilite la lecture du dataset.
La mise en place d'une **liste contrôlée de périodes** (Antiquité, Moyen Âge, Moderne, Contemporaine, etc.) permettrait d'harmoniser les données et de rendre les analyses chronologiques plus fiables.

Cette normalisation doit s'appuyer sur les informations présentes dans la colonne *synthèse*, qui constitue la principale source d'indications temporelles.

7.2 Nettoyage

Aucun nettoyage supplémentaire majeur n'est nécessaire à ce stade.
Les colonnes vides ont été fusionnées ou supprimées, et les dates ont été normalisées.

> **Résultat :** Le dataset est désormais suffisamment stable pour envisager une restructuration plus fine des champs patrimoniaux.

Il n'est donc pas nécessaire d'ajouter d'autres opérations de nettoyage.

7.3 Restructuration

La colonne *période* doit être **reconstruite intégralement**.
Chaque ligne doit être renseignée à partir des informations contenues dans la *synthèse*, en combinant :

- une extraction automatique de mots-clés (gallo-romain, médiéval, antique, abbaye, etc.) ;
- une vérification manuelle pour les cas ambigus ou non datés.

> **Interprétation :** Cette approche hybride garantit une meilleure précision tout en restant réaliste pour un corpus hétérogène.

La documentation des choix opérés est essentielle pour assurer la transparence scientifique et permettre une réutilisation future du dataset.

7.4 Préparation à la migration

En vue d'une intégration dans PostgreSQL/PostGIS, plusieurs champs doivent être préparés :

- **code_postal** : normalisation des valeurs pour garantir la cohérence géographique ;
- **adresse** : harmonisation des formats pour faciliter les jointures et les recherches ;
- **longitude** et **latitude** : vérification de la validité des coordonnées et préparation à la conversion en géométrie PostGIS.

Même si la conception d'un modèle de table cible dépasse ton niveau actuel — ce qui est parfaitement normal — le dataset nettoyé est déjà compatible avec une structure relationnelle classique.

> **Recommandation :** La migration doit s'accompagner d'un travail de curation documentaire, notamment sur les champs temporels et patrimoniaux.

La migration ne pose donc pas de difficulté technique majeure, à condition d'accompagner le processus d'une structuration préalable des champs essentiels.

8. Conclusion

Le travail exposé dans ce notebook a permis de montrer en application le processus complet de transformation de données. Le fichier brut initial a été transformé, structuré et analysé, afin de pouvoir être utilisé dans des contextes variés : recherche, médiation, exploration ou développement d'outils numériques.

L'analyse exploratoire a permis de mettre en évidence l'intérêt scientifique du corpus, mais aussi ses défauts, notamment son caractère hétérogène : formats différents, valeurs manquantes, incohérences, colonnes inutilisées mais malgré tout présentes... Autant de points qui justifient un travail en profondeur.

Le travail de nettoyage, normalisation et de structuration a permis de rendre les données lisibles et opérables sans les dénaturer. Une fois cette tâche effectuée, les données sont intégrées dans une base relationnelle PostgreSQL enrichie de PostGIS, nous permettant de faire des analyses plus fines (exploration spatiale, typologies des opérations, dynamiques temporelles...). Ces mêmes analyses sont présentées dans ce notebook sous formes de vues thématiques et démontrent le potentiel d'une pipeline moderne appliqué à des données archéologiques.

Car au delà de l'exercice technique, ce projet montre l'intérêt d'employer les méthodes issues de la science des données et comment ces dernières peuvent contribuer à une meilleure compréhension du territoire, à la valorisation des archives archéologiques et la création d'outils accessibles à des publics variés. Il s'inscrit dans une véritable démarche de médiation scientifique : rendre les données lisibles, exploitables et partageables, sans sacrifier ni leur complexité ni leur profondeur historique.

En conclusion, ce travail pose ainsi les fondations d'un envrionnement de données fiable, documenté et évolutif, capable de soutenir des projets de recherche, de médiation ou d'innovation numérique autour du patrimoine archéologique parisien.

Résumé synthétique du dataset

Aspect analysé	Constats principaux	Impact	Action recommandée
Périodes	Colonnes vides ; info cachée dans la synthèse	Perte d'information chronologique	Extraction + normalisation
Typologies	Majorité = "découverte_ancienne"	Faible granularité	Normalisation terminologique
Localisation	Forte densité dans le 5e arrondissement	Clusters invisibles sans carte	Visualisation spatiale
Responsables	Forte diversité ; acteurs non spécialisés	Variabilité des descriptions	Documentation + contextualisation
Dates	Normalisées mais parfois peu précises	Chronologie partielle	Enrichissement si possible
Migration	Structure compatible	Risques documentaires	Curation des champs sensibles

Résumé visuel

Tableau synthétique du dataset

Aspect	Constat	Impact	Action
Périodes	Colonnes vides ; info dans la synthèse	Perte d'information chronologique	Extraction + normalisation
Typologies	Majorité = "découverte_ancienne"	Granularité faible	Normalisation terminologique
Localisation	Forte densité dans le 5e	Clusters invisibles sans carte	Visualisation spatiale

Responsables	Acteurs variés, parfois non spécialistes	Variabilité des descriptions	Documentation + contextualisation

---

Pipeline de traitement des données

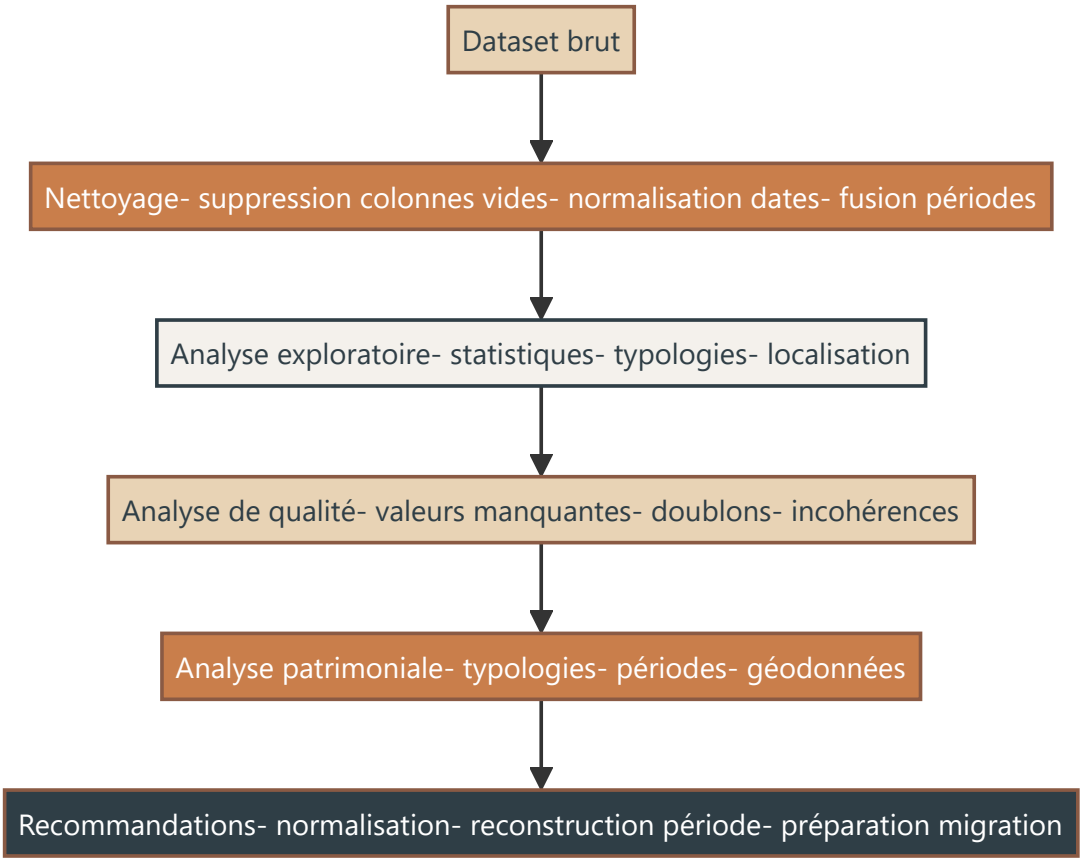

Schéma logique du traitement des données

Dataset brut ↓ 1. Nettoyage

- Suppression des colonnes vides
- Normalisation des dates
- Fusion des champs de période

  ↓
  2. Analyse exploratoire

- Statistiques descriptives
- Typologies
- Périodes (via synthèse)
- Localisation

↓

3. Analyse de qualité

- Valeurs manquantes
- Doublons
- Formats
- Incohérences

↓

4. Analyse patrimoniale

- Typologies hétérogènes
- Périodes antiques / médiévales
- Concentration spatiale
- Champs sensibles

↓

5. Recommandations

- Reconstruction du champ période
- Normalisation terminologique
- Préparation à la migration

↓

6. Perspectives

- Carte interactive
- Catalogue thématique
- Intégration PostGIS